

# **djlmmp\_sentiment\_analyzer: Um modelo para Análise de Sentimento com base em *Tweets***

**Diego Oliveira Aluizio<sup>1</sup>, Jônatas Garcia de Oliveira<sup>1</sup>, Livia Alabarse dos Santos<sup>1</sup>,  
Marina Scabello Martin<sup>1</sup>, Pedro Henrique Araujo Farias<sup>1</sup>**

<sup>1</sup>Faculdade de Computação e Informática (FCI)  
Universidade Presbiteriana Mackenzie - São Paulo, SP - Brasil

{diego.aluizio,jonatasgarcia.oliveira, liviaalabarse.santos,  
marina.martin, pedrohenriquearaujo.farias}@mackenzista.com.br

**Abstract.** *This work describes the development of a sentiment analysis model for tweets about the invasion of the Three Powers on January 8, 2023. Using the Tweet\_Eleições\_2022 dataset, the group manually annotated tweets as positive, negative, or neutral. A model based on BERTimbau Base was trained with TensorFlow and Transformers and made available on the Hugging Face Hub. A Streamlit application was created to use the model for sentiment analysis, allowing users to submit texts individually or via a spreadsheet. The model's code and notebook are available on GitHub and Google Colab, respectively.*

**Resumo.** *Este trabalho descreve o desenvolvimento de um modelo de análise de sentimentos em tweets sobre a invasão dos Três Poderes em 8 de janeiro de 2023. Utilizando o dataset Tweet\_Eleições\_2022, o grupo anotou manualmente tweets como positivos, negativos ou neutros. Um modelo baseado no BERTimbau Base foi treinado com TensorFlow e Transformers e disponibilizado no Hugging Face Hub. Uma aplicação Streamlit foi criada para usar o modelo na análise de sentimentos, permitindo submeter textos individualmente ou via planilha. O código e notebook do modelo estão disponíveis no GitHub e Google Colab, respectivamente.*

## 1. Introdução

Este trabalho tem como objetivo desenvolver um modelo de classificação de sentimentos (positivo, negativo e neutro) em tweets relacionados à invasão dos Três Poderes em 8 de janeiro de 2023. Este evento foi amplamente discutido nas redes sociais, especialmente no Twitter, que se configurou como uma fonte de dados crucial para análise de percepções e discursos públicos.

A pesquisa baseia-se no dataset **Tweet\_Eleições\_2022** (SILVA et al., 2024), que reúne aproximadamente 9,5 milhões de tweets coletados ao longo do processo eleitoral brasileiro de 2022, via a API oficial do *Twitter* (Twitter Developer Platform, 2022). Embora o dataset esteja publicamente disponível em versão desidratada — ou seja, sem o conteúdo textual integral e metadados sensíveis, em respeito à privacidade dos usuários — este estudo possui acesso privilegiado aos dados hidratados completos, graças à participação de uma das pesquisadoras no projeto **HEIWA** (projeto de pesquisa do grupo CIBERDEM<sup>1</sup>).

Esse acesso exclusivo possibilitou a realização de análises qualitativas e quantitativas mais aprofundadas, imprescindíveis para a tarefa de classificação de sentimentos. Todo o processo foi conduzido respeitando as normas éticas de pesquisa em ambiente digital, incluindo anonimização dos dados.

## 2. O Que é PLN (Processamento de Linguagem Natural)

Antes de explorarmos o processo em detalhes, é fundamental entender o conceito de Processamento de Linguagem Natural (PLN), que envolve técnicas computacionais para análise e interpretação de dados textuais. Processamento de Linguagem Natural (PLN) é uma subárea da Inteligência Artificial que combina linguística e computação para extrair significado de textos, com aplicações em análise de sentimentos, tradução e sumarização.

Para que o PLN seja capaz de interpretar o significado por trás das palavras e frases, ele emprega uma série de técnicas computacionais. Isso envolve etapas como a remoção de ruídos (pontuação ou palavras que não acrescentam ao significado do texto), a tokenização (divisão do texto em unidades menores) e a normalização (padronização de termos). Esses processos preparam os dados para que algoritmos de aprendizado de máquina possam identificar padrões, classificar informações e, por fim, realizar tarefas propostas, como a análise de sentimento.

A complexidade do PLN em ambientes como o Twitter se acentua pela natureza informal e altamente contextualizada da linguagem utilizada, repleta de abreviações, gírias, ironias e emojis, fatores que tornam o pré-processamento e a modelagem mais desafiadores e, ao mesmo tempo, mais ricos em possibilidades analíticas.

## 3. Coleta dos Dados

Os dados utilizados neste estudo foram originalmente coletados entre agosto e dezembro de 2022, por meio da API oficial do Twitter, que permite a obtenção de conteúdos públicos mediante parâmetros específicos de consulta.

---

<sup>1</sup> <https://ciberdem.mack.com.br/>

O corpus inicial contém cerca de 9,5 milhões de tweets, abrangendo diversas manifestações sobre o processo eleitoral brasileiro. Para o recorte temático desta pesquisa, realizamos um pré-processamento que consistiu em três etapas principais:

- **Remoção de duplicatas:** a fim de garantir que análises e modelagens não fossem enviesadas por múltiplas ocorrências de um mesmo conteúdo.
- **Filtragem temporal:** restringimos o conjunto de dados ao dia 8 de janeiro de 2023, visando capturar exclusivamente as manifestações relativas à invasão das sedes dos Três Poderes.
- **Anonimização:** as informações que pudessem identificar indivíduos (como nomes de usuários, IDs ou links) foram removidas ou codificadas, em conformidade com os princípios éticos estabelecidos pelo projeto Heiwa e pelas políticas do Twitter.

#### 4. Processo de Anotação de Validação

Com o corpus pré-processado, iniciou-se o processo de **anotação manual** dos dados. A anotação consistiu na atribuição de uma das três categorias de sentimento — **positivo, negativo ou neutro** — a cada tweet, com base na análise do conteúdo textual.

Essa tarefa foi realizada pelo grupo, previamente orientados para garantir a uniformidade de critérios na classificação. Para tornar o processo mais eficiente separamos aleatoriamente 200 tweets para cada anotador. Esta distribuição garantiu que cada membro pudesse realizar a tarefa com atenção, favorecendo a qualidade das anotações.

Após a anotação, realizou-se uma validação adicional, na qual divergências foram discutidas coletivamente até se alcançar um consenso. Esse rigor metodológico foi essencial para assegurar a qualidade das labels e, conseqüentemente, a eficácia do modelo de aprendizado supervisionado a ser desenvolvido.

#### 5. Dados Pós-Anotação

O conjunto final de dados, após a etapa de anotação e validação, assumiu a estrutura representada na Tabela 1.

**Tabela 1. Atributos da base de dados**

Atributo	Descrição
conversation_id	Identificador numérico único associado a cada tweet
text	O conteúdo textual integral do tweet, previamente pré-processado para remoção de ruído, como URLs, menções e hashtags descontextualizadas.
Sentimento	Categoria de sentimento atribuída ao tweet (positivo, negativo ou neutro), a qual será utilizada como variável dependente na tarefa de modelagem preditiva.

O modelo é treinado a partir de exemplos rotulados para aprender a inferir a categoria de novos textos. O equilíbrio entre as classes foi monitorado, a fim de evitar

problemas relacionados a dados desbalanceados, que podem prejudicar o desempenho do modelo.

## 6. Modelo para Classificação

Para a instanciação e treinamento do modelo de análise de sentimento, foram empregadas as bibliotecas *TensorFlow*<sup>2</sup> e *Transformers*<sup>3</sup>. A arquitetura do modelo foi derivada do modelo pré-treinado **BERTimbau Base**<sup>4</sup>, o qual foi submetido a um processo de *fine-tuning* utilizando o *dataset* descrito nas seções anteriores.

Na etapa de *fine-tuning*, algumas camadas do BERTimbau foram congeladas, resultando na otimização de um subconjunto reduzido de parâmetros. Adicionalmente, a camada de classificação foi reconfigurada para comportar três classes de sentimento: positivo, negativo e neutro.

Concluído o treinamento, o modelo foi enviado à plataforma *Hugging Face Hub*, viabilizando seu carregamento e utilização em aplicações externas. O *pipeline* completo de desenvolvimento, treinamento e avaliação do modelo foi executado e documentado neste [notebook do Google Colab](#).

## 7. Aplicação Streamlit

Para consumo do modelo, foi desenvolvida uma aplicação *Streamlit*<sup>5</sup> que o instancia a partir do *Hugging Face Hub*, empregando-o para a execução de tarefas de análise de sentimento em dados textuais.

A aplicação permite ao usuário submeter um único texto para análise imediata ou realizar o *upload* de um arquivo em formato de planilha (.csv ou .xlsx) contendo um conjunto de textos para processamento. Após a análise, a aplicação exibe a classificação de sentimento resultante para o texto individual. No caso de *upload* de planilha, é exibido um arquivo de planilha contendo os textos originais e uma coluna adicional com as respectivas predições de sentimento. Além disso, o usuário pode realizar *download* do arquivo resultante nos formatos .csv e .xlsx.

A aplicação foi hospedada na plataforma *Streamlit Cloud*<sup>6</sup>, e pode ser acessada a partir deste [link](#). Seu código-fonte está alocado e disponível no [repositório GitHub do projeto](#).

## 8. Resultados

Como resultados deste projeto, temos um modelo para classificação de textos com base em seu sentimento e uma aplicação disponível na *web* que permite a execução da análise de sentimento de textos a partir do consumo deste modelo.

---

<sup>2</sup> <https://www.tensorflow.org/?hl=pt-br>

<sup>3</sup> <https://huggingface.co/docs/transformers/en/index>

<sup>4</sup> <https://huggingface.co/neuralmind/bert-base-portuguese-cased>

<sup>5</sup> <https://streamlit.io/>

<sup>6</sup> <https://streamlit.io/cloud>

Abaixo, deixamos algumas capturas de tela do *notebook* utilizado para configuração e treinamento do modelo, bem como da aplicação que utiliza o mesmo para realizar a classificação do sentimento dos textos inseridos pelo usuário:

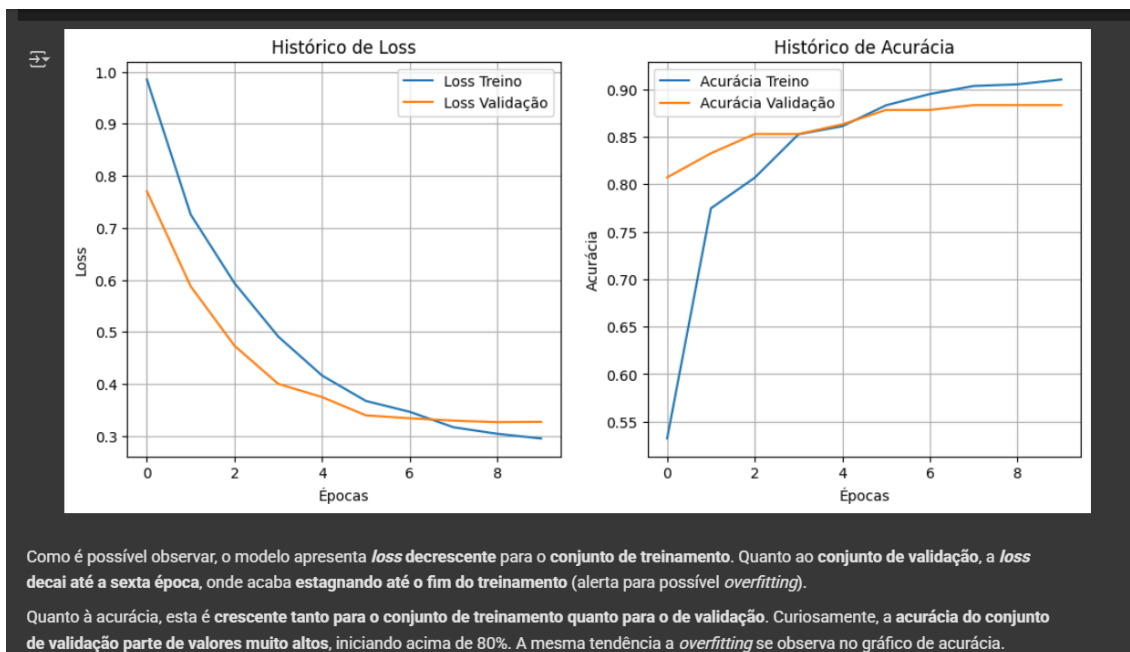


Figura 1: Gráficos de avaliação de *loss* e *accuracy* do modelo treinado. Fonte: autores.

**Análise de Sentimento de Textos em Português**

Utilize um modelo fine-tuned para analisar o sentimento de um texto ou de uma planilha!

☒ Análise de Texto Único ☐ Análise de Arquivo (CSV/XLSX)

**Analisar um único texto**

Digite o texto que você gostaria de analisar:

Ex: Adorei o novo filme, os efeitos especiais são incríveis!

**Analisar Texto**

Figura 2: Aba de análise de sentimento de texto único na aplicação desenvolvida. Fonte: autores.

## 9. Conclusão

Este trabalho desenvolveu uma ferramenta para analisar sentimentos (positivo, negativo ou neutro) a partir de *tweets* sobre a invasão dos Três Poderes em 8 de janeiro de 2023. Essa base de dados foi preparada e classificada manualmente para treinar um modelo de inteligência artificial, desenvolvido a partir do ajuste fino do modelo pré-treinado BERTimbau Base, a reconhecer esses sentimentos. O modelo final foi disponibilizado no *Hugging Face* para livre utilização.

Além disso, desenvolvemos uma aplicação *Streamlit* que permite a qualquer pessoa usar esse modelo para analisar o sentimento de textos, seja um de cada vez ou vários a partir de uma planilha. Tanto o código-fonte da aplicação quanto o *notebook* de treinamento do modelo estão disponíveis para consulta. Assim, este projeto não apenas aprofundou o conhecimento dos autores sobre coleta e tratamento de dados, treinamento de modelos de aprendizagem de máquina e atividades de processamento de linguagem natural, como também permitiu a criação e documentação de um artefato para estudo de todos os tópicos supracitados.

## Referências

- Abadi, M. et al. TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems. 2015. Disponível em: <https://www.tensorflow.org/>. Acesso em: 01 jun. 2025.
- Alura. (24 de novembro de 2021). Guia de NLP - conceitos e técnicas. Disponível em: <https://www.alura.com.br/artigos/guia-nlp-conceitos-tecnicas> Acesso em: 01 jun. 2025.
- Deep Charts. The Easiest Way to Deploy A Streamlit App. [Publicado em 16 de junho de 2024]. YouTube. Disponível em: <http://www.youtube.com/watch?v=JL9xOs-G1hI> Acesso em: 1 de jun. de 2025.
- DeepLearning.AI. (11 de janeiro de 2023). Natural Language Processing (NLP) [A Complete Guide]. [Artigo online]. Disponível em: <https://www.deeplearning.ai/resources/natural-language-processing/>
- Hashtag Programação. (30 de julho de 2024). Curso de Streamlit - Aula 1 - Como Funciona Criar Apps e Sites com o Streamlit. [Vídeo]. YouTube. Disponível em: <http://www.youtube.com/watch?v=Nsja-c8596k>
- HUGGING FACE. Compartilhando modelos pré-treinados. Disponível em: <https://huggingface.co/learn/llm-course/pt/chapter4/3>. Acesso em: 1 jun. 2025.
- HUGGING FACE. Tokenizer. Disponível em: [https://huggingface.co/docs/transformers/main\\_classes/tokenizer](https://huggingface.co/docs/transformers/main_classes/tokenizer). Acesso em: 1 jun. 2025.
- HUGGING FACE. Uploading models. Disponível em: <https://huggingface.co/docs/hub/models-uploading>. Acesso em: 1 jun. 2025.
- Silva, L. et al. Tweet\_Eleições\_2022: Um dataset de tweets durante as eleições presidenciais brasileiras de 2022. In: BRAZILIAN WORKSHOP ON SOCIAL NETWORK ANALYSIS AND MINING (BRASNAM), 13., 2024, Brasília/DF. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2024. p. 193-199. DOI 10.5753/brasnam.2024.1940. Disponível em:

<https://sol.sbc.org.br/index.php/brasnam/article/view/29343>. Acesso em: 30 maio 2025.

Souza, F. neuralmind/bert-base-portuguese-cased. [S. l.]: Hugging Face, 2020. Disponível em: <https://huggingface.co/neuralmind/bert-base-portuguese-cased>. Acesso em: 1 jun. 2025.

Talebi, S. Fine-Tuning BERT for Text Classification (w/ Example Code). [Publicado em 17 de out. de 2024]. Disponível em: <http://www.youtube.com/watch?v=4QHg8Ix8WWQ>. Acesso em: 1 de jun. de 2025.

Wolf, T. et al. HuggingFace's Transformers: State-of-the-art Natural Language Processing. CoRR, v. abs/1910.03771, 2019. Disponível em: <http://arxiv.org/abs/1910.03771>. Acesso em: 1 jun. 2025.